

Hlboké neurónové siete 2026


Zadanie č. 1

Na príklade klasifikácie terénu pre mobilný robot na základe vibračnej analýzy z meraných signálov akcelerometra, gyroskopu a magnetometra porovnajte MLP, LSTM a CNN siete.

Na základe demonštračných ukážok v prednáške pre rozpoznávanie číslíc 0-9 (dataset MNIST) a rozpoznávanie druhov oblečenia (dataset FashionMNIST) pomocou viacvrstvovej perceptrónovej siete (MLP) a konvolučnej neurónovej siete (CNN), tiež aj na základe príkladu rozpoznávania dynamických gest pomocou LSTM siete (číslíc 0 až 9 zaznamenané na Kinecte) vytvorte a natrénujte MLP, LSTM a CNN siete, ktoré budú schopné klasifikovať (rozpoznávať) terén na základe signálov zo snímačov. Ako vstupy použite signály aspoň z dvoch snímačov. Realizáciu zadania môžete robiť v prostredí Matlab alebo Python.

Stručné informácie k datasetu:


Databáza obsahuje namerané dáta od akcelerometra, gyroskopu a magnetometra. Pre každý snímač boli uložené hodnoty v x,y,z -ovom smere. Časové postupnosti jednotlivých snímačov boli uložené do "csv"súborov. V prípade inerciálnych snímačov boli hodnoty odčítané s frekvenciou 400 Hz, a v prípade magnetometra vzorkovacia frekvencia bola nastavená na 100 Hz. V trénovacej sade bolo nameraných 6 druhov terénov:



(a) Betón



(b) Tráva



(c) Kamienky



(d) Piesok



(e) Dlažobný kameň



(f) Syntetická bežecká dráha

Obr. 1 Ukážky druhov terénov nameraných v datasete


Výstupné triedy boli rovnomerne rozložené v databáze. Každý "csv"súbor obsahoval jedno meranie, ktoré trvalo 4 až 6 sekúnd. Pri meraní tvorcovia databázy používali dve rôzne plnenia širokopásmovej modulácie pre mobilný robot. Najprv plnenie bolo nastavené na konštantnú hodnotu 86 % a v druhom prípade na 100%. Z meraní posuvným oknom vyberte 1s úseky, kde

okno posúvajte o 0,5s. (t.j. pre ACC a GYR, bude mať okno 400 vzoriek a posuv bude o 200). Až tieto časové úseky použijete na tréningovanie a testovanie neurónových sietí.

Pri vytváraní a tréningovaní MLP, LSTM a CNN siete použijete preddefinované rozdelenie dát na tréningové, validačné a testovacie dáta. Pre každý terén je nameraných 14 meraní, náhodne 10 vyberte na tréningovanie, 2 na validáciu a 2 na testovanie. V tréningovacom procese využívate tréningové a validačné dáta, kde na tréningových realizujete tréningovanie a podľa chyby a úspešnosti klasifikácie na validačných dátach upravujete parametre tréningovania. Testovacie dáta sú použité na testovanie siete po natréningovaní, kde pre natréningovanú NS vyčísľete percentuálnu úspešnosť klasifikácie. Nastavte štruktúru siete a parametre tréningovania, tak aby ste dosiahli čo najväčšiu percentuálnu úspešnosť klasifikácie na testovacích dátach. Pri odovzdávaní treba vedieť zdôvodniť nastavenie týchto parametrov. Pre naladenú štruktúru siete vykonajte 5 spustení s náhodným rozdelením dát (alebo krížovú validáciu) a vyčísľete priemernú úspešnosť klasifikácie na validačných a testovacích dá. Pre najlepšie natréningované siete zobrazte aj kontingenčnú maticu. Navzájom porovnajte jednotlivé neurónové siete.

Klasifikácia terénu pomocou MLP siete (manuálna extrakcia príznakov):

Klasifikácia terénu pomocou MLP siete potrebuje manuálne počítať príznaky, na základe ktorých sa robí samotná klasifikácia do tried. Príznaky sa môžu počítať v časovej alebo frekvenčnej oblasti.



Obr. 2 Bloková schéma pre klasifikáciu terénu s manuálnym výpočtom príznakov

Vo frekvenčnej oblasti sa najčastejšie používa Rýchla Fourierova transformácia (FFT). Použitím FFT algoritmu dostaneme informácie o dynamike časového signálu. Vstupom transformácie je časový vektor s N prvkami reálnych čísel a výstupom je komplexná frekvenčná charakteristika signálu tiež s N prvkami. Výsledný vektor môžeme rozdeliť na magnitúdovú (M) a na fázovú (θ) frekvenčnú charakteristiku pomocou vzťahov:

$$M = \sqrt{x^2 + y^2} \quad \theta = \text{atan2}(x, y)$$

Kde x je reálna a y je imaginárna zložka frekvencií. Výsledné vektory FFT transformácie sa môžeme považovať za príznaky klasifikácie.

V časovej oblasti počítame rôzne napr. štatistické hodnoty ako minimálna, maximálna alebo priemerná hodnota priamo zo signálov snímača. Tu sú uvedené príznaky vhodné na klasifikáciu terénu.

1. Priemerná absolútna hodnota (MAV):

$$MAV = \frac{1}{N} \sum_{i=1}^N |x_i|$$

Kde N je počet vzoriek v sekvencii a x_i je i-ty prvok merania

2. Počet prechodov nulou (NZC)

$$NZC = \sum_{i=1}^{N-1} [sgn(x_i * x_{i+1}) \cap |x_i - x_{i+1}| \geq th]$$

Kde th je prahová hodnota, a sgn reprezentuje znamienko výsledku

3. Počet zmien sklonových značiek (NSSC)

$$NSSC = \sum_{i=2}^{N-1} = f((x_i - x_{i-1}) * (x_i - x_{i+1})), f(x) = \begin{cases} 1, & \text{pre } x \geq 0 \\ 0, & \text{inak} \end{cases}$$

4. Odmocnina kvadrátu priemeru (RMS)

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$$

5. Dĺžka priebehu (WL)

$$WL = \sum_{i=1}^N |x_{i+1} - x_i|$$

6. Willisonova amplitúda (WAMP)

$$WAMP = \sum_{i=1}^{N-1} f(x_i - x_{i+1})$$

7. Maximálna hodnota (MAX)


8. Minimálna hodnota (MIN)

9. Dĺžka vlny (Peak-to-peak) (PTP)

$$PTP = MAX - MIN$$

Klasifikácia terénu pomocou LSTM a CNN siete (automatická extrakcia príznakov):

Klasifikácia terénu pomocou LSTM a CNN siete nepotrebuje manuálne počítať príznaky, tieto štruktúry neurónových sietí si ich dokážu počítať priamo zo signálov snímačov. Pri CNN sieťach sa v konvolučných vrstvách použije 1D konvolúcia.



Obr. 3 Bloková schéma pre klasifikáciu terénu s automatickým výpočtom príznakov

Sumarizácia úloh:

1. Vykonajte porovnanie priebehov tréovania, chyby a úspešnosti pre vybrané štruktúry sietí (optimalizácia štruktúry siete, odporúčané 3), zdôvodnenie výberu štruktúry siete. (možnosť ukázania vplyvu DropOut vrstvy)
2. Vykonajte porovnanie priebehov tréovania, chyby a úspešnosti pri vybraných parametroch tréovania, napr.:
 - Optimalizátor učenia SGDM alebo ADAM (AdamW)
 - krok učenia (learning rate) , napr. 0.01, 0.001, 0.0001
 - veľkosť dávky – minibatchsize
 - počet tréovacích epoch napr. 10, 15, 20
3. Porovnajte dosiahnuté výsledky (úspešnosti klasifikácie) pre MLP, LSTM a CNN sieť na validačných a testovacích dátach (pri porovnaní berte priemer z 5 opakovaní).
4. Pre najlepšie natréované štruktúry sietí, zobrazte kontingenčné matice a porovnajte ich.

Poznámka: Adresár „utils“

Tento adresár obsahuje pomocné zdrojové kódy. V súbore „train_func“ sú uložené funkcie, ktoré uľahčujú tréovacie a validačné procesy. Dáta bola predspracovaná v zdrojových kódach s názvami „prepare_data“ a „prepare_time_series“. Súbor „featue_extraction“ je modul na extrahovanie časových príznakov z meraní. Zdrojové kódy „visualise“ a „visu“ sú programy na porovnanie časových priebehov meraní pri rôznych terénov.