

Hlboké neurónové siete 2026

Projekt č. 1

Cieľ úlohy:

Porovnajte trénovanie vybraných modelov konvolučných neurónových sietí, vizuálnych transformerov a hybridných modelov. Na trénovanie modelov použite transferové učenie - transfer learning (TL) a pridelený dataset. Cieľom je overiť, ako sa pri rovnakom probléme mení úspešnosť klasifikácie, stabilita výsledkov a priebeh učenia pri rôznych architektúrach modelov a nastavení parametrov trénovania.

Porovnávajúte nasledovné modely:

1. M1 – CNN: ResNet alebo MobileNet alebo EfficientNet (vybrať vhodný model a verziu)
2. M2 – CNN + attention vrstva: Model M1 + CBAM
3. M3 – Optimalizovaná CNN: ConvNeXt
4. M4 – Vizuálny transformer: ViT, DeiT, Swin
5. M5 – Hybridný model: CoAtNet

Pridelený Dataset náhodne rozdeľte v pomere 80% dát na trénovanie a 10% dát na validáciu a 10% dát na testovanie (Např. z datasetu z každej skupiny vyberiem 1000 vzoriek – 800 trénovanie, 100 validácia, 100 testovanie). V prípade malého počtu dát si pohľadajte iný zdroj obrazov a rozšírite dataset, alebo validačné data použite aj na testovanie. Pred trénovaním modelov nastavte vhodné parametre trénovania. Pri prezentácii projektu zdôvodnite výber štruktúry a parametrov trénovania. Snažte sa používať rovnaké parametre trénovania pri všetkých modeloch. Pre každý model spustite trénovanie 3-krát a výsledky štatisticky vyhodnoťte.

Pre najlepšie natrénovaný model z každého typu zobrazte proces trénovania (priebeh Loss a Acc na trénovacích a validačných dátach). Na testovacích obrazových dátach nepoužitých v trénovaní vykonajte testovanie jednotlivých modelov a vyčísľte úspešnosť ACC, presnosť Precision a senzitivitu Recall. Pre testovacie data robzte aj kontingenčnú tabuľku.

Aspoň pre jeden model ukážte vplyv augmentácie na úspešnosť klasifikácie. Porovnajte pri vybranej štruktúre siete trénovanie bez augmentácie a s augmentáciou.

Aspoň pre jeden model realizujte postupné rozmrazovanie vrstiev (alebo trénovanie od nuly) predtrénovanej siete a sledujte vplyv na úspešnosť klasifikácie.

Datasety:

Na trénovanie CNN sietí použite nasledovné vybrané obrazy z datasetov (GitHub <https://github.com/STU-FEI-OUI/HNS-Projekt1/edit/main/README.md>, Goggle disk, HNS_2025/Cvicenia/Projekt1/Datasety_Projekt1 alebo Kaggle datasety:

1. Dataset Vozidlá - Vehicles Dataset

Klasifikácia obrazov, 6 skupín (auto, autobus, bicykel, motorka, dodávka, pickup)
https://drive.google.com/drive/folders/1ETypjMKG3aPFdnf-RIiWp82HwKq1R4nX?usp=drive_link

Doplňť obrazy vozidiel je možné cez datasety MS COCO, ImageNet dataset, alebo Kaggle
<https://www.kaggle.com/datasets/iamsandeepprasad/vehicle-data-set>

2. Dataset Dopravné Značky - Traffic Signs Dataset

Klasifikácia obrazov, 12 skupín (vybrané typy značiek)

https://drive.google.com/drive/folders/1JShYe8vmZv287GCPLxERNt2PP3C3hwZv?usp=drive_link

3. Dataset Vnútorné prostredie - InDoor Dataset

Klasifikácia obrazov, 9 skupín (vnútorné priestory reštaurácia, obývačka, spálňa, kuchyňa, ...)

https://drive.google.com/drive/folders/1nWlwbR2opcynCSwm_WN97URv_WC-3MVy?usp=drive_link

4. Dataset Ochorenia Paradajok - Plant Village 2

Klasifikácia obrazov, 9 skupín ochorenia listov paradajok (zdravé, 8 skupín ochorenia)

https://drive.google.com/drive/folders/1sKmmi0L4KeSf5xgxXhldCrks4oF897DX?usp=drive_link

Tiež je k dispozícii na Kaggle , <https://www.kaggle.com/datasets/emmarex/plantdisease>

5. Dataset Počasie - Weather Dataset

Klasifikácia obrazov, 11 skupín počasia (dew, fogsmog, frost, glaze, hail, lightning, rain, rainbow, rime, sandstorm, snow)

<https://www.kaggle.com/code/adrianograms/weather-image-classification/input>

Doplniť obrazy počasia je možné cez datasety na Kaggle

https://drive.google.com/drive/folders/1XMSb5IRHJP8PhjMwVJNal7SmHFOduRij?usp=drive_link

<https://www.kaggle.com/code/ramazanturann/weather-image-classification/input>

6. Dataset Architektúry - Architecture Dataset

Klasifikácia obrazov, 25 skupín typov architektúr budov

https://drive.google.com/drive/folders/13hPJY3ZBmGQp1_AwKQUTMrs3ei2GhFvs?usp=drive_link

7. Dataset Kvety - Flowers Dataset

Klasifikácia obrazov, 5 druhov kvetov (daisy, dandelion, rose, sunflower, tulip)

<https://www.kaggle.com/code/nikhilmishra21/flowers-notebook-cnn/input>

8. Dataset Kvety - Flowers Dataset – Oxford 102 flowers

Klasifikácia obrazov, 102 druhov kvetov (použiť minimálne 10 tried, ktoré sú najviac zastúpené)

<https://www.robots.ox.ac.uk/~vgg/data/flowers/102/>

9. Dataset Jedlá - Foods Dataset

Klasifikácia obrazov jedál, 101 skupín obrazov jedál, (použiť minimálne 10 tried, ktoré sú najviac zastúpené), <https://www.kaggle.com/datasets/kmader/food41>

10. Dataset Odpadky 1 - Garbage 1 Dataset

Klasifikácia obrazov odpadkov, 10 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2>

11. Dataset Odpadky 2 - Garbage 2 Dataset

Klasifikácia obrazov odpadkov, 6 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/asdasdasdasdas/garbage-classification/data>

12. Dataset Odpadky 3 - Garbage 3 Dataset

Klasifikácia obrazov odpadkov, 12 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

13. Dataset na detekciu požiaru lesov - Forest Fire Smoke Dataset

Rozpoznávanie požiaru lesov, 3 skupiny Smoke, Fire, Not_Fire
<https://www.kaggle.com/datasets/amerzishminha/forest-fire-smoke-and-non-fire-image-dataset>

14. Dataset PC komponentov – PC components Dataset

Rozpoznávanie PC komponentov, 14 skupín (CPU, GPU, káble, RAM, HDD, monitor, klávesnica, ...)
<https://www.kaggle.com/datasets/asaniczka/pc-parts-images-dataset-classification>

15. Dataset povrchových defektov ocelového pásu – NEU Surface defect Dataset

Klasifikácia defektov ocelového plechu, 6 skupín (valcované okuje (RS), škvrny (Pa), praskliny (Cr), jamkovitý povrch (PS), inklúzie (In) a škrabance (Sc))
<https://www.kaggle.com/datasets/kaustubhdikshit/neu-surface-defect-database/data>

Výsledky projektu zaznamenajte do dokumentácii a spolu s programami vložte do AISu do 7. týždňa.