

Hlboké neurónové siete 2026

Projekt č. 1

Na základe demonštračných ukážok v prednáške pre rozpoznávanie predmetov na obrazoch (dataset Caltech) pomocou predtrénovanej konvolučnej neurónovej siete (AlexNet), natrénujte 4 typy predtrénovaných CNN (napr. AlexNet, VGG16, ResNet50 (18), GoogleNet, Inception v3, MobileNet,, Xception, EfficientNet,...) a dva typy vlastnej štruktúry (jedna sériové zapojenie, jedna sériovo – paralelné zapojenie)

Na tréning CNN sietí použite nasledovné vybrané obrázky z datasetov (Goggle disk, HNS_2025/Cvicenia/Projekt1/Datasety_Projekt1 alebo Kaggle datasety), kde CNN budú realizovať triedenie obrazov do jednotlivých skupín:

1. Dataset Vozidlá – 6 skupín (auto, autobus, bicykel, motorka, dodávka, pickup) (minimum 1500 vzoriek v skupine) - doplniť obrázky MS COCO, ImageNet dataset, <https://www.kaggle.com/datasets/iamsandeepprasad/vehicle-data-set>
2. Dataset Značky – 12 vybraných dopravných značiek (minimum 1000 vzoriek v skupine)
3. Dataset Indoor – 9 skupín (vnútorné priestory reštaurácia, obývačka, spálňa, kuchyňa, ...) (vybrať 500 vzoriek v skupine, 400 tréningové, 100 validácia)
4. Dataset PlantVillage2 – 9 skupín ochorenia listov paradajok (zdravé, 8 skupín ochorenia) (minimum 1000 vzoriek v skupine)
5. Dataset Weather – 5 skupín počasia (cloudy, foggy, rainy, snowy, sunny) (vybrať 1200 vzoriek v skupine, 1000 tréningové, 200 validácia)
6. Dataset Architektúra – 25 skupín typov architektúr (použiť minimálne 300, ideálne všetky data)
7. Dataset Flowers – Oxford 102 flowers dataset (použiť minimálne 10 tried, ktoré sú najviac zastúpené) (<https://paperswithcode.com/dataset/oxford-102-flower>)
8. Dataset Foods – (použiť triedy z 1000 a viac vzorkami, Food Image Classification , <https://www.kaggle.com/code/gauravduttakiit/class-dataset-food-image-classification/input>)
9. Dataset 3D printing errors (4 triedy klasifikácie, normal a 3 triedy defektov) – <https://www.kaggle.com/datasets/nimbus200/3d-printing-errors>
10. Garbage dataset 1 (10 tried odpadu) - <https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2>
11. Garbage dataset 2 (6 tried odpadu) - <https://www.kaggle.com/datasets/zlatan599/garbage-dataset-classification>
12. Forst,fire,smoke: (Dataset na detekciu požiaru, 3 triedy) <https://www.kaggle.com/datasets/amerzishminha/forest-fire-smoke-and-non-fire-image-dataset>

Dataset náhodne rozdeľte v pomere 80% dát na tréningovanie a 20% dát na validáciu. (Např. z datasetu z každej skupiny vyberiem 1000 vzoriek – 800 tréningovanie, 200 validáciu). Ako testovacie data si pohľadajte iný zdroj obrazov, alebo použite validačné data. Pred tréningovaním nastavte štruktúry sietí a parametre tréningovania. Zdôvodnite výber štruktúry a parametrov tréningovania. Tréningovanie pre každú sieť opakujte 3 krát a vyčíslite úspešnosti klasifikácie.

Pre najlepšie natréňovanú sieť z každého typu zobrazte proces tréningovania a kontingenčnú tabuľku. Na iných obrazových dátach nepoužitých v tréningovaní vykonajte testovanie jednotlivých sietí a vyčíslite úspešnosť.

Pre celkovo najlepšie natréňovanú CNN, zobrazte vybrané filtre v 1. a 2. konvolučnej vrstve, zobrazte výslednú mapu príznakov pre vybraný vstupný obraz.

Zmenšite počet vzoriek na tréningovanie a ukážte vplyv augmentácie na úspešnosť klasifikácie. Porovnajte pri vybranej štruktúre siete tréningovanie bez augmentácie a s augmentáciou.

Vyskúšajte si realizovať postupné rozmrazovanie vrstiev predtrénovanej siete a odsledujte vplyv na úspešnosť klasifikácie.

Výsledky projektu zaznamenajte do dokumentácii a spolu s programami vložte do AISu do 7. týždňa.