

Hlboké neurónové siete 2026

Zadanie č. 1

Cieľ úlohy:

Na príklade klasifikácie terénu pre mobilný robot na základe vibračnej analýzy z meraných signálov akcelerometra, gyroskopu a magnetometra porovnajte MLP, LSTM, CNN siete a SVM klasifikátor.

Na základe demonštračných ukážok v prednáške pre rozpoznávanie číslíc 0-9 (dataset MNIST) a rozpoznávanie druhov oblečenia (dataset FashionMNIST) pomocou viacvrstvovej perceptrónovej siete (MLP) a konvolučnej neurónovej siete (CNN), tiež aj na základe príkladu rozpoznávania dynamických gest pomocou LSTM siete (číslíc 0 až 9 zaznamenané na Kinecte) vytvorte a natrénujte SVM klasifikátor a MLP, LSTM, CNN siete, ktoré budú schopné klasifikovať (rozpoznávať) terén na základe signálov zo snímačov. Ako vstupy použite signály aspoň z dvoch snímačov. Realizáciu zadania môžete robiť v prostredí Matlab alebo Python.

V tréningovom procese využívate tréningové a validačné dáta, kde na tréningoch realizujete tréningovanie a podľa chyby a úspešnosti klasifikácie na validačných dátach upravujete parametre tréningovania. Testovacie dáta sú použité na testovanie siete po natréningovaní, kde pre natréningovanú NS vyčísľete percentuálnu úspešnosť klasifikácie. Nastavte štruktúru siete a parametre tréningovania, tak aby ste dosiahli čo najväčšiu percentuálnu úspešnosť klasifikácie na testovacích dátach. Pri odovzdávaní treba vedieť zdôvodniť nastavenie týchto parametrov. Pre naladenú štruktúru siete vykonajte 5 spustení s náhodným rozdelením dát (alebo krížovú validáciu) a vyčísľete priemernú úspešnosť klasifikácie na validačných a testovacích dá. Pre najlepšie natréningované siete zobrazte aj kontingenčnú maticu. Navzájom porovnajte jednotlivé klasifikačné modely.


Stručné informácie k datasetu:

Databáza obsahuje namerané dáta od akcelerometra, gyroskopu a magnetometra. Pre každý snímač boli uložené hodnoty v x, y, z -ovom smere. Časové postupnosti jednotlivých snímačov boli uložené do "csv"súborov. V prípade inerciálnych snímačov boli hodnoty odčítané s frekvenciou 400 Hz, a v prípade magnetometra vzorkovacia frekvencia bola nastavená na 100 Hz. V tréningovej sade bolo nameraných 6 druhov terénov:



Obr. 1 Ukážky druhov terénov nameraných v datasete

Výstupné triedy boli rovnomerne rozložené v databáze. Každý "csv" súbor obsahoval jedno meranie, ktoré trvalo 4 až 6 sekúnd. Pri meraní tvorcovia databázy používali dve rôzne plnenia širokopásmovej modulácie pre mobilný robot. Najprv plnenie bolo nastavené na konštantnú hodnotu 86 % a v druhom prípade na 100%. Z meraní posuvným oknom vyberte 1s úseky, kde okno posúvajte o 0,5s. (t.j. pre ACC a GYR, bude mať okno 400 vzoriek a posuv bude o 200). Až tieto časové úseky použijete na tréning a testovanie neurónových sietí.




Obr. 2 Zobrazenie priebehov merania z akcelerometra ACC_1_3_7 a 1s okna (od 0.5s do 1.5s)

Pri vytváraní a tréningu MLP, LSTM a CNN siete použijete preddefinované rozdelenie dát na tréningové, validačné a testovacie data. Pre každý terén je nameraných 14 meraní, náhodne 10 vyberte na tréning, 2 na validáciu a 2 na testovanie.

Teoretický opis klasifikačných metód:

Klasifikácia terénu pomocou SVM klasifikátora a MLP siete (manuálna extrakcia príznakov):

Klasifikácia terénu pomocou SVM klasifikátora a MLP siete potrebuje manuálne počítať príznaky, na základe ktorých sa robí samotná klasifikácia do tried. Príznaky sa môžu počítať v časovej alebo frekvenčnej oblasti.



Obr. 2 Bloková schéma pre klasifikáciu terénu s manuálnym výpočtom príznakov

Príznaky (Features) vo frekvenčnej oblasti

Vo frekvenčnej oblasti sa najčastejšie používa Rýchla Fourierova transformácia (FFT). Použitím FFT algoritmu dostaneme informácie o dynamike časového signálu. Vstupom transformácie je časový vektor s N prvkami reálnych čísel a výstupom je komplexná frekvenčná charakteristika signálu tiež s N prvkami. Výsledný vektor môžeme rozdeliť na magnitudovú (M) a na fázovú (θ) frekvenčnú charakteristiku pomocou vzťahov:

$$M = \sqrt{x^2 + y^2} \quad \theta = \text{atan2}(x, y)$$

Kde x je reálna a y je imaginárna zložka frekvencií. Výsledné vektory FFT transformácie sa môžeme považovať za príznaky klasifikácie.

Príznaky (Features) v časovej oblasti

V časovej oblasti počítame rôzne napr. štatistické hodnoty ako minimálna, maximálna alebo priemerná hodnota priamo zo signálov snímača. Tu sú uvedené príznaky vhodné na klasifikáciu terénu.

1. Priemerná absolútna hodnota (MAV):

$$MAV = \frac{1}{N} \sum_{i=1}^N |x_i|$$

Kde N je počet vzoriek v sekvencii a x_i je i-ty prvok merania

2. Počet prechodov nulou (NZC)

$$NZC = \sum_{i=1}^{N-1} [sgn(x_i * x_{i+1}) \cap |x_i - x_{i+1}| \geq th]$$

Kde th je prahová hodnota, a sgn reprezentuje znamienko výsledku

3. Počet zmien sklonových značiek (NSSC)

$$NSSC = \sum_{i=2}^{N-1} = f((x_i - x_{i-1}) * (x_i - x_{i+1})), f(x) = \begin{cases} 1, & \text{pre } x \geq 0 \\ 0, & \text{inak} \end{cases}$$

4. Odmocnina kvadrátu priemeru (RMS)

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$$

5. Dĺžka priebehu (WL)

$$WL = \sum_{i=1}^N |x_{i+1} - x_i|$$

6. Willisonova amplitúda (WAMP)

$$WAMP = \sum_{i=1}^{N-1} f(x_i - x_{i+1})$$

7. Maximálna hodnota (MAX)

8. Minimálna hodnota (MIN)


9. Dĺžka vlny (Peak-to-peak) (PTP)

$$PTP = MAX - MIN$$

Každý snímač má 3 signály (osi X, Y, Z), to znamená 9 krát 3 príznakov pre jeden snímač, pri použití akcelerometra a gyroskopu bude spolu 54 príznakov pre jeden 1s časový výrez.

Klasifikácia terénu pomocou LSTM a CNN siete (automatická extrakcia príznakov):

Klasifikácia terénu pomocou LSTM a CNN siete nepotrebuje manuálne počítať príznaky, tieto štruktúry neurónových sietí si ich dokážu počítať priamo zo signálov snímačov. Pri CNN sieťach sa v konvolučných vrstvách použije 1D konvolúcia.



Obr. 3 Bloková schéma pre klasifikáciu terénu s automatickým výpočtom príznakov

Sumarizácia úloh:

1. Pre prvú štruktúru siete vykonajte porovnanie priebehov trénovania, chyby a úspešnosti pri vybraných parametroch trénovania, napr.:
 - Optimalizátor učenia SGDM alebo ADAM (AdamW)
 - krok učenia (learning rate) , napr. 0.01, 0.001, 0.0001
 - veľkosť dávky – minibatchsize
 - počet trénovacích epoch napr. 10, 15, 20
2. Vykonajte porovnanie priebehov trénovania, chyby a úspešnosti pre vybrané štruktúry sietí (optimalizácia štruktúry siete, odporúčané 3), zdôvodnenie výberu štruktúry siete. (možnosť ukázania vplyvu DropOut vrstvy)
3. Porovnajte dosiahnuté výsledky (úspešnosť klasifikácie, presnosť, senzitivita) pre SVM klasifikátor, MLP, LSTM a CNN sieť na validačných a testovacích dátach (pri porovnaní berte priemer z 5 opakovaní).
4. Pre najlepšie natrénované štruktúry sietí, zobrazte kontingenčné matice a porovnajte ich.

Postup:

1. Narežte merané signály na 1s okná s posunom 0.5s, podľa pokynov v zadaní.
2. Rozdeľte data na tréningové, validačné a testovacie, podľa pokynov v zadaní. (Pre každý terén je nameraných 14 meraní, náhodne 10 vyberte na tréningovanie, 2 na validáciu a 2 na testovanie.)
3. Pre SVM klasifikátor a MLP sieť vypočítajte z 1s časových úsekov príznaky (časové alebo frekvenčné)
4. Pre jednotlivé typy modelov nastavte parametre tréningovania, snažte používať čo najviac parametrov rovnakých. (zdôvodnite nastavenie parametrov)
5. Pre každý typ modelu otestujte ešte 2 ďalšie štruktúry siete.
6. Pre najlepšiu štruktúru spustite 5 krát tréningovanie a vypočítajte minimálne, maximálne a priemerné hodnoty metrík (úspešnosť, presnosť, senzitivita) (accuracy, precision, recall) na validačných a testovacích dátach.
7. Porovnajte do tabuľky dosiahnuté výsledky (úspešnosť, presnosť, senzitivita) pre SVM klasifikátor, MLP, LSTM a CNN sieť na validačných a testovacích dátach (pri porovnaní berte priemer z 5 opakovaní).

Poznámka: Adresár „utils“

Tento adresár obsahuje pomocné zdrojové kódy. V súbore „train_func“ sú uložené funkcie, ktoré uľahčujú tréningové a validačné procesy. Dáta bola predspracovaná v zdrojových kódach s názvami „prepare_data“ a „prepare_time_series“. Súbor „feature_extraction“ je modul na extrahovanie časových príznakov z meraní. Zdrojové kódy „visualise“ a „visu“ sú programy na porovnanie časových priebehov meraní pri rôznych terénoch.